

TRABALHO INTEGRADOR 1 - IFFAGLE

1. Descrição do Trabalho

O objetivo deste trabalho é desenvolver um sistema de indexação e busca de arquivos armazenados em uma pasta do sistema operacional. Por essa razão, o nome *IFFar Google* -> *IFFagle*.

O sistema deverá receber como entrada uma pasta definida pelo usuário e realizar uma varredura de seu conteúdo, incluindo, quando aplicável, os arquivos existentes em suas subpastas. A partir dessa varredura, o sistema deverá construir um índice de arquivos, o qual será possível realizar pesquisas sem a necessidade de percorrer novamente toda a estrutura de diretórios. O projeto deverá contemplar dois tipos principais de arquivos:

- Imagens (pelo menos jpg e png);
- Documentos textuais (pelo menos txt).

O sistema deverá permitir pesquisar os arquivos indexados por diferentes critérios e apresentar os resultados ordenados por relevância, disponibilizando uma interface Web para consulta dos resultados (similar à tela original do Google).


O trabalho deverá ser desenvolvido na linguagem de programação de preferência do grupo, desde que todos os requisitos especificados neste documento sejam atendidos.


2. Objetivos do Trabalho

1. Selecionar uma pasta do sistema operacional para indexação;
2. Percorrer a pasta e suas subpastas;
3. Identificar os arquivos encontrados;
4. Armazenar informações relevantes sobre cada arquivo;
5. Construir uma estrutura de dados do tipo Árvore para permitir buscas eficientes;
6. Criar um índice separado para imagens e documentos;
7. Permitir pesquisas por nome e tipo de arquivo (imagens ou documentos):
 - 7.1. Para imagens, pesquisar por metadados;
 - 7.2. Para documentos, pesquisar pelo conteúdo;
9. Calcular uma medida de relevância para os resultados;
10. Ordenar os resultados de acordo com essa relevância;
11. Disponibilizar os resultados através de uma aplicação Web;
12. Permitir visualizar ou acessar os arquivos encontrados;
13. Apresentar um relatório sobre as estruturas de dados e algoritmos utilizados e suas justificativas.

3. Funcionamento Esperado do Trabalho

De maneira simplificada, o sistema deverá funcionar conforme o fluxo abaixo:





A implementação interna fica a critério dos alunos, mas o sistema deverá efetivamente utilizar alguma estrutura de dados do tipo **Árvore indexação e pesquisa**. Os dados a serem armazenados nessa estrutura de dados é de escolha

do grupo. Todavia, recomenda-se que o nome do arquivo e o caminho completo sejam, de alguma forma, armazenados.

Considerando a complexidade do trabalho, a relevância dos resultados só será exigida para os documentos, o qual o grupo deverá percorrer o conteúdo do documento a fim de gerar uma nova estrutura de dados listando as palavras mais comuns daquele documento, que deverá ser utilizado como critério para mostrar os resultados da busca ao usuário.

Para conclusão do trabalho, permitirá-se o uso de bibliotecas externas, entretanto, as principais estruturas de dados e algoritmos relacionados ao processo de indexação deverão ser implementados pelo próprio grupo, sendo proibido o uso de uma biblioteca pronta. Por exemplo, se o grupo resolver trabalhar com PDF, poderá utilizar uma biblioteca para extrair o conteúdo de um PDF. Por outro lado, fazer uso de uma biblioteca que implemente uma árvore qualquer, fazendo com que o desenvolvedor não precise se preocupar com mecânica de funcionamento dessa árvore, não é permitido.

Observação final, a princípio, todos os arquivos presentes na pasta devem ter autorização de leitura, contudo, como o usuário é quem vai indicar uma pasta a ser utilizada pelo sistema, o grupo precisa se preocupar com a possibilidade de que nem todos os arquivos existentes no computador necessariamente poderão ser acessados. Desta forma, caso o sistema encontre um arquivo ou pasta sem permissão de leitura, o programa deverá ignorar o item e continuar a indexação dos demais arquivos. Em outras palavras, o programa não deverá ser encerrado simplesmente porque encontrou um arquivo que não pode ser lido.

4. Entregáveis do Trabalho

O grupo deverá entregar uma documentação contendo, no mínimo:

1. Introdução: descrição do problema e da solução proposta;
2. Tecnologias utilizadas: linguagem, bibliotecas, frameworks;
3. Estruturas de dados utilizadas: quais e por quê;
4. Limitações: apresentar as limitações conhecidas do sistema.